

Analyse de réseaux de financement européen

Open data · multiplexe · métriques · visualisations

Nourane Hammouda

Encadrant : Valentin Bouquet

Réalisation du 18 mars au 22 mai 2026

Auteure : Nourane Hammouda

Encadrant : Valentin Bouquet

Période : 18 mars – 22 mai 2026

Dépôt : projet-graphe-recherche-eu

Compilation : XeLaTeX · rapport/premium/main.tex

Remerciements

Je remercie **Valentin Bouquet** pour l'encadrement et le cadrage méthodologique du projet. Je remercie également les équipes qui maintiennent les portails **CORDIS** et **OpenAlex**, sans lesquels l'approche répliquable sur données ouvertes ne serait pas possible.

Table des matières

Remerciements	i
1 Introduction	1
1.1 Contexte et positionnement	1
1.2 Vue d'ensemble du travail réalisé	1
1.3 Problématiques opérationnelles	1
2 Environnement de travail	2
2.1 Matériel, système et dépôt	2
2.2 Environnement Python	2
2.3 Rédaction du rapport (L ^A T _E X)	2
3 Description du projet et objectifs	2
3.1 Périmètre et livrables	3
3.2 Encadrement méthodologique	3
3.3 Positionnement du multiplexe	3
4 Bibliothèques, Outils et technologies	3
4.1 Modèles numériques et assistance IA	4
5 Travail réalisé	4
5.1 Sources ouvertes : jeux téléchargés et fichiers bruts importés	4
5.2 Traitement relationnel (<code>clean_normalize.py</code>) : logiques d'extraction	5
5.3 Exports graphes après normalisation	5
5.4 Opportunités de collaboration : définition quantitative	7
5.5 Statistiques sur l'exemplaire traité (<code>data/processed/</code>)	8
5.6 Méthodologie et chaîne de traitement	8
5.7 Modélisation, exports et fonctionnalités des graphes	8
5.8 Pipeline logiciel et architecture	9
5.9 Algorithmes de graphes (rappel opérationnel)	9
5.10 Visualisations interactives	9
5.11 Résultats quantitatifs (indicatifs)	10
6 Difficultés rencontrées	10
7 Bilan	10
7.1 Conclusion	10
7.2 Perspectives	11

Abstract (English)	12
8 Bibliographie	13
9 Webographie	14
A Cahier des charges	15
A.1 Contexte et périmètre	15
A.2 Exigences fonctionnelles	15
A.3 Exigences non fonctionnelles	15
A.4 Critères de réception (indicatifs)	15
B Exemple d'exécution du projet	15
B.1 Préparation de l'environnement	15
B.2 Pipeline complet (extrait type)	16
B.3 Arborescence indicative après exécution	16
B.4 Compilation du présent rapport	16
B.5 Lecture programmatique de la synthèse métriques	16
C Manuel utilisateur	16
C.1 Objectif	16
C.2 Lancer le pipeline	16
C.3 Carte interactive et suite multi-vues	17
C.4 Paramètres utiles	17
C.5 Dépannage (aperçu)	17

1 Introduction

Conformité au canevas. Ce document suit le plan imposé : sections *Introduction* à *Bilan*, puis bibliographie, webographie et annexes. Le format est A4 en 12 pt avec les marges du canevas. Les figures et tableaux sont cités explicitement dans le texte (par ex. figure 1 et tableau 1).

1.1 Contexte et positionnement


Les politiques de financement de l'Union européenne produisent des **traces relationnelles riches** : co-participation à des projets, montants engagés, paysage institutionnel et, via des référentiels complémentaires, des liens vers littérature scientifique et concepts thématiques. La modélisation en graphe permet d'extraire des signaux structurels au-delà de tableaux agrégés.

Réseau de co-financement

Un **graphe de collaboration explicite** $G_{\text{ex}} = (V, E)$: sommets V = organisations, arête $\{u, v\} \in E$ s'il existe au moins un projet où u et v reçoivent une contribution européenne. Poids entier : nombre de projets en commun.

1.2 Vue d'ensemble du travail réalisé

Insight. Chaîne complète : **ingestion open data** (CORDIS, OpenAlex), **normalisation relationnelle**, construction d'un **graphe multiplexe** (collaboration explicite, similarité thématique, bipartitions financement/projet), calcul de **métriques de réseau** (PageRank, Louvain, betweenness, contrainte de Burt), et **visualisations interactives** (Folium, fiches HTML, carte pays, démo bipartite, suite multi-vues `interactive_suite.html`).




Synthèse volumétrique indicative (échantillon traité)—alignée sur les exports `data/processed/`.

1.3 Problématiques opérationnelles

- **Résilience d'identité** : déduplication robuste d'organisations (noms variables, identifiants hétérogènes).
- **Échelle** : millions d'évènements de co-présence potentiels—choix algorithmiques (approximation, filtrage d'affichage).

- **Hétérogénéité** : articuler *fait financier* (CORDIS) et *signal thématique* partiel ou externe (OpenAlex).
- **Opportunités de collaboration** : définir et prioriser les paires “proches” sur le graphe *thématique* mais absentes du graphe *explicite* CORDIS—sans confondre corrélation thématique et intention ou faisabilité contractuelle réelle ; le détail du calcul figure en section 5.4.
- **Communication** : rendre les résultats navigables pour décideurs et analystes (*storytelling* cartographique, suite HTML à onglets).



Exemple de cœur dense
(schéma pédagogique)

FIGURE 1 – Dans G_{ex} , la forme locale (triangles, ponts) informe brokers et robustesse collaborative.

2 Environnement de travail

2.1 Matériel, système et dépôt

Le projet `projet-graphe-recherche-eu` s'exécute typiquement sous **macOS** ou **Linux** avec **Python 3**. La racine du dépôt contient `src/` (scripts), `data/raw/`, `data/processed/`, `data/graphs/` et ce rapport sous `rapport/premium/main.tex`.

2.2 Environnement Python

Création d'un environnement virtuel (`python3 -m venv env`), activation, puis `pip install -r requirements.txt` (ou `requirements-core.txt` si contraintes de version). Le point d'entrée orchestré est `src/run_pipeline.py` avec paramètres de volumétrie (`--max-rows`, `--max-pages`).

2.3 Rédaction du rapport (L^AT_EX)

Ce document est compilé en **XeLaTeX** (Unicode, polices OpenType TeX Gyre). Si le système ne résout pas les polices par nom, les chemins `fontpathTGYre` en tête de `main.tex` pointent vers les `.otf` du *texmf*.

3 Description du projet et objectifs

3.1 Périmètre et livrables

Réaliser une chaîne **open data** → **tables normalisées** → **graphes multiplexes** → **métriques** → **visualisations** sur le financement européen : identifier des organisations, leurs collaborations contractuelles (CORDIS), enrichir par publications et concepts (OpenAlex), calculer des centralités et communautés, produire une carte interactive (Folium), des fiches organisations, et une **interface unique** regroupant plusieurs HTML (`data/graphs/interactive_suite.html`).

3.2 Encadrement méthodologique

La littérature des **réseaux scientifiques et d'innovation** mobilise souvent des bi-partis acteurs–artefacts, des projections pondérées, et des indicateurs de centralité / modularité¹. Les données ouvertes imposent nettoyage d'identifiants et contrôle de qualité.

3.3 Positionnement du multiplexe

L'approche combine (i) une couche **explicite** (co-financement) ; (ii) une couche **latente** (profils thématiques / similarité) ; (iii) des **scores de centralité** pour prioriser l'exploration.

Insight. Le multiplexe autorise des **recouvrements informatifs** (qui collabore vs qui ressemble) et des *écarts* exploitables—par ex. paires thématiquement proches sans arête CORDIS, pour recommandations d'opportunité.

4 Bibliothèques, Outils et technologies

TABLE 1 – Bibliothèques et rôle dans le projet.

Composant	Usage
pandas / NumPy	CSV/JSON, jointures, matrices.
NetworkX	Graphes, GEXF, PageRank, betweenness (échantillonnée), contrainte Burt, Louvain [5].
scikit-learn	TF-IDF + L2 pour opportunités dans <code>visualize_folium.py</code> .
Folium / Pyvis	Cartes HTML et démos réseau.
requests / httpx / pyarrow	APIs et E/S.
matplotlib	Figures complémentaires.
Torch / sentence-transformers / FAISS / cdlib / recordlinkage	Présents pour extensions (non requis au flux minimal documenté).

1. Communautés (Louvain, Leiden), revues comme [4, 2].

4.1 Modèles numériques et assistance IA

- **Cœur thématique** : profils *bag-of-concepts* + similarité cosinus (`build_thematic_layer.py`).
- **Carte** : TF-IDF n-grammes sur corpus agrégé par organisation.
- **IA générative** : assistance au développement et à la documentation (ex. fichiers de contexte projet) ; les métriques publiées proviennent des scripts et des données ouvertes, pas d'une inférence LLM sur le jeu CORDIS.

5 Travail réalisé

5.1 Sources ouvertes : jeux téléchargés et fichiers bruts importés

5.1.1 CORDIS (Commission européenne)

Le script `src/fetch_cordis.py` télécharge automatiquement les exports officiels (fichiers `.csv` ou archives `.zip`) depuis <https://cordis.europa.eu/data> : jeux projets et organisations pour **Horizon 2020** (`cordis-h2020*`...) et **Horizon Europe** (`cordis-he*`..., variantes de casse dans les URL gérées par le script). Après téléchargement, des versions *écrêtées* (option `--max-rows`) sont écrites dans `data/raw/cordis/` sous les noms canoniques suivants lorsque les jeux sont complets :

- `h2020_projects_trimmed.csv`, `he_projects_trimmed.csv` (métadonnées projets) ;
- `h2020_organizations_trimmed.csv`, `he_organizations_trimmed.csv` (participations financées par projet).

Le parseur utilise le séparateur **point-virgule** et l'encodage `UTF-8-sig`, ce qui reflète la distribution standard CORDIS. Sur un dépôt partiel (par exemple uniquement Horizon 2020), seuls les fichiers effectivement téléchargés sont pris en compte dans l'étape de normalisation.

5.1.2 OpenAlex

Le script `src/fetch_openalex.py` interroge l'API REST `works` (<https://api.openalex.org/works>) avec un filtre sur le bailleur **Commission européenne** (`awards.funder_id:`) des paramètres `--max-pages` et `--per-page`, et une pagination par `cursor`. Le corpus collecté est stocké comme une **liste JSON** dans `data/raw/openalex/works_ec_funded.json`.

5.1.3 OpenAIRE (optionnel)

La collecte OpenAIRE est déclenchée uniquement lorsque `src/run_pipeline.py` est invoqué avec `--include-openaire` (`src/fetch_openaire.py`) ; elle peut enrichir ou croiser avec d'autres identifiants, mais n'est pas requise pour le flux documenté ci-dessous.

5.2 Traitement relationnel (`clean_normalize.py`) : logiques d'extraction

Lecture CORDIS. Les tableaux projets et organisations sont lus avec détection souple des noms de colonnes (`pick_column`) : par exemple `id` / `projectID` pour l'identifiant projet, `ecContribution` / `netEcContribution` pour le montant, `geolocation` pour `lat`, `lon`, etc. Les budgets textuels sont convertis en flottants (virgule remplacée si besoin).

Identifiant stable d'organisation (`org_id`). Si CORDIS fournit un identifiant non vide (PIC, numéro interne, TVA, etc.), il est normalisé et concaténé au code pays pour former `org_id`. Sinon, un hachage **SHA-1** (`digest[:10]`) est calculé sur la chaîne concaténée `nom|ville|type` afin de stabiliser les fusions lorsque l'identifiant source manque (`make_org_id`).

Projection "co-projets". Pour chaque projet regroupant au moins deux organisations, toutes les paires distinctes sont générées ; le fichier `edges_org_org_explicit.csv` contient une ligne par paire avec le poids `weight_common_projects = nombre de projets en commun`. Le fichier `edges_org_project.csv` matérialise la participation pondérée (montant européen) d'une organisation à un projet (`source_org_id`, `target_project_id`, `weight_eur`). Le tableau `organizations.csv` agrège par organisation : budget total perçu, nombre de projets distincts, coordonnées (géocode CORDIS si présent).

Ouverture via OpenAlex. Les institutions citées dans OpenAlex sont normalisées de la même manière que `org_name_norm` côté CORDIS. La jointure textuelle **exacte sur la normalisation du nom** alimente `edges_org_publication.csv` puis, via les concepts attachés aux œuvres, `edges_org_concept.csv` où le poids d'une paire (`org`, `concept`) est la **somme des scores OpenAlex** des concepts au fil des publications liées à l'organisation.

5.2.1 Contrôle qualité et provenance




FIGURE 2 – Heatmap pédagogique (axes qualité symboliques).

5.3 Exports graphes après normalisation

5.3.1 Couche collaboration explicite (`build_graph.py`)

Le graphe multiplexe est exporté en **GEXF** sous `data/graphs/collab_explicit.gexf`. Il représente organisations, projets et publications ainsi que les arêtes de finan-

TABLE 2 – Huit tables normalisées sous `data/processed/ (*.csv)` et fichier OpenAlex brut associé.

Fichier relatif	Rôle (schéma logique)
<code>organizations.csv</code>	Une ligne par <code>org_id</code> : dénomination, pays, ville, type, budgets agrégés, <code>nb_projects</code> .
<code>projects.csv</code>	Projet (titre, dates, enveloppe financière indicative, lien programme).
<code>publications.csv / concepts.csv</code>	Table des œuvres OpenAlex (+ concepts et scores lorsque présents).
<code>edges_org_project.csv</code>	Financement européen (poids euros) Org → Projet.
<code>edges_org_org_explicit.csv</code>	Graphe projeté <i>explicite</i> Org–Org avec poids = # projets communs.
<code>edges_org_publication.csv</code>	Lien après appariement de noms Org → Publication.
<code>edges_org_concept.csv</code>	Profil thématique par organisation (somme des scores concept).
<code>data/raw/openalex/works_ec_funded.json</code>	Source brute API OpenAlex utilisée avant fusion.

TABLE 3 – Exemples de contrôles pipeline.

Axe	Contrôle
Couverture	géolocalisation, ratio renseigné
Cohérence	$\text{budgets} \geq 0$, clés résolues
Lignée	<code>data_provenance_report.json</code>

cement, de co-participation et les liens attribution–publication. La couche utilisée dans `src/algorithms.py` pour PageRank ou Louvain est le **sous-graphe des organisations** lorsque les nœuds portent `node_type=organization`, avec pondération selon les poids agrégés d’arête.

5.3.2 Couche thématique (`build_thematic_layer.py`)

À partir de `edges_org_concept.csv`, on construit une matrice creuse **organisation** $\times$ **concept** où chaque coefficient est la somme des scores de concepts observés pour l’organisation. Les lignes sont normalisées en norme euclidienne (éviter division par zéro), puis la **similarité cosinus** entre chaque paire d’organisations (i, j) est le produit scalaire des vecteurs unitaires correspondants. Une arête du graphe thématique implicite G_{th} est créée si la similarité s_{ij} vérifie $s_{ij} \geq \theta$, avec $\theta = 0,30$ par défaut (`--threshold`). Le fichier produit est `data/graphs/thematic_implicit.gexf`. Les couples (i, j) thématiquement liés mais **sans** arête dans `edges_org_org_explicit.csv` constituent des candidats préliminaires d’« opportunité ».

5.4 Opportunités de collaboration : définition quantitative

Le script `src/gap_analysis.py` matérialise l’écart entre *similarité thématique* et *collaboration CORDIS observée*.

Sélection des paires candidates. Pour chaque arête de G_{th} de poids $s = \text{weight}$ (la similarité cosinus) :

1. si $s < \text{min_score}$ (valeur par défaut **0,40**, option `--min-score`), la paire est rejetée ;
2. si la même paire d’organisations apparaît déjà comme collaboration explicite dans `edges_org_org_explicit.csv`, elle est **exclue** (ce n’est pas un “trou”, mais une collaboration avérée).

Priorisation multi-critères (`gap_analysis.py`). Notons `broker_bonus = 1` lorsque au moins une organisation appartient à l’ensemble des *relays* défini comme intersection d’un fort betweenness dans le graphe explicite et d’un classement parmi les 30 % meilleures valeurs positives de contrainte de Burt sur le graphe thématique (`burt_constraint_thematic` issue de `organization_metrics.json`). Soient c valant 1 si les deux pays diffèrent, t valant 1 si les deux types juridiques diffèrent, et $\text{balance} = \min\{n_{\text{proj}}^{(a)}, n_{\text{proj}}^{(b)}\} / \max\{n_{\text{proj}}^{(a)}, n_{\text{proj}}^{(b)}\}$ le rapport équilibrant les volumes projet. La priorité retenue est

$$\pi = 0,60s + 0,15\text{broker_bonus} + 0,10c + 0,10t + 0,05\text{balance}, \quad (1)$$

puis coupée dans $[0, 1]$ et arrondie. Les seuils métier suivants attribuent une étiquette `priority_label` : $\pi \geq 0,80$ « Très forte », $\geq 0,65$ « Forte », $\geq 0,55$ « Intermédiaire », sinon « À surveiller ».

Livrables JSON. Jusqu'à 3 000 fiches sont triées selon (`priority_score` décroissant, `thematic_score` décroissant) puis écrites dans `data/graphs/gap_analysis_top.json` (champs : identifiants, scores, budgets, attributs booléens transfrontaliers/trans-types, rattache broker). Sur l'exemplaire mesuré pour ce rapport, le fichier contenait 1 674 paires après filtrage—aussi moins que le plafonnement 3000 lorsque peu de couples passent successivement les seuils θ et `min_score`.

5.5 Statistiques sur l'exemplaire traité (`data/processed/`)

Les grandeurs suivantes résultent du comptage automatique sur le dépôt au moment de la rédaction (cf. tableau 4) ; elles permettent d'objectiver l'échelle lors de la défense tout en demeurant **dépendantes** des paramètres `--max-rows` / réseau télé-chargé.

TABLE 4 – Volumes et agrégats sur l'exemplaire local (ordre de grandeur projet).

Mesure	Va
Organisations uniques (<code>organizations.csv</code>)	41
Codes pays institutionnels distincts*	
Somme budgets perçus CORDIS (<code>budget_total_received</code>)	≈ 68,1 G€ (68 071 318 274,54 € bruts agrégés)
Projets listés (<code>projects.csv</code>)	34
Lignes financement org→projet (<code>edges_org_project.csv</code>)	178
Paires collaborations explicites (<code>edges_org_org_explicit.csv</code>)	1 145
Associations org→concept (<code>edges_org_concept.csv</code>)	4
Œuvres OpenAlex retenues (<code>publications.csv</code>)	
Nœuds / arêtes dans G_{th} (export GEXF)	160 / 2
Communities Louvain (collaboration vs thème)	4 39
Paires dans <code>gap_analysis_top.json</code>	1
Premier rang PageRank collaborations (<code>metrics_summary.json</code>)	≈ 5,285×

* Champ pays non vide ; codes erronés ou manquants réduisent mécaniquement ce décompte.

5.6 Méthodologie et chaîne de traitement

Principes : traçabilité raw → processed → graphs, scripts re-jouables, séparation calcul batch / rendu HTML. Validité interne (jointures) *vs* externe (lisibilité métier).




FIGURE 3 – Chaîne de traitement.

5.7 Modélisation, exports et fonctionnalités des graphes

Multiplexe explicite (`collab_explicit.gexf`) : nœuds organisation / projet / publication et arêtes financement, co-projet, authorship (`build_graph.py`). **Sous-graphe org** pour PageRank, betweenness, Louvain (`algorithms.py`).

Thématique implicite (`thematic_implicit.gexf`) : cosinus sur matrice $\text{org} \times \text{concepts}$, seuil `--threshold`. **Écarts** : `gap_analysis_top.json`; **TF-IDF** sur la carte pour opportunités complémentaires. Script `embed_organizations.py` pour profils concepts compacts.




FIGURE 4 – Co-participation et projection explicite (schéma).

5.8 Pipeline logiciel et architecture

```
fetch_* -> clean_normalize -> build_graph / build_thematic_layer /
gap_analysis -> algorithms -> visualize_folium
```

Triptyque *data / compute / viz*; filtrage d’affichage PageRank sur la carte, HTML atomique, reprise si métriques absentes (fallback `nb_projects`).

5.9 Algorithmes de graphes (rappel opérationnel)

Parcours (BFS/DFS), plus courts chemins (Dijkstra), PageRank, Louvain [3], betweenness échantillonnée, contrainte de Burt—implémentations et sources dans `src/algorithms`. et dépendances NetworkX.

5.10 Visualisations interactives

- **Carte réseau de recherche** : `research_network_map_folium.html`—marqueurs, popups, couches collaboration / thématique, liens vers fiches `org_profiles/`. Les “top organisations” du panneau sont les plus fortes en `pagerank_collab` (PageRank sur le sous-graphe org-org explicite, arêtes pondérées), parmi les organisations conservées après filtres programme et top- N , avec budget en second critère.
- **Carte collaborations pays** : `country_collaborations_map.html`—vue macro des liens transnationaux.
- **Démo bipartite multi-projets** : `demo_multi_project_pair.html`—exemple CNRS ↔ CEA (vis-network, tableaux filtrables).
- **Suite unique (onglets)** : `interactive_suite.html` agrège les trois vues précédentes dans une même interface navigateur avec navigation par sections cliquables et chargement paresseux des iframes pour préserver le dimensionnement Leaflet.

5.11 Résultats quantitatifs (indicatifs)

Synthèse issues de `metrics_summary.json` sur la base complète typique : 41 706 nœuds org, 1 145 155 arêtes collaboratives, 4 391 communautés Louvain (collab.); graphe thématique 160 nœuds, 2 737 arêtes, 9 communautés. Exemple top PageRank : DE_DE129515865... à 0,00528, etc.




FIGURE 5 – Volumétrie (log) collaboration *vs* thématique.

6 Difficultés rencontrées

- **Schémas CORDIS hétérogènes** : mapping souple de colonnes et IDs manquants nécessitant un hachage composite pour `org_id`.
- **Échelle** : betweenness exacte irréaliste ; échantillonnage et bornes `--max-edges` pour la carte.
- **Alignement OpenAlex ↔ organisations** : appariement par nom normalisé, faux positifs possibles.
- **Navigateur** : HTML volumineux ; filtrage top-*N* pour rester fluide.
- **L^AT_EX XeLaTeX** : résolution des polices TeX Gyre selon l'OS.
- **Dépendances Python** : Torch / versions ; recours à `requirements-core.txt` sur certaines plateformes.

Alerte méthodo. Les limites de **couverture** CORDIS/OpenAlex et d'interprétation causale des centralités demeurent : voir bilan.

7 Bilan

7.1 Conclusion

Ce projet formalise une chaîne reproductible `open data` → `graphe` → `métriques` → `visualisation` sur le financement européen, avec multiplexe explicite/thématique et interface cartographique. Les points forts incluent la modularité des scripts, une échelle réaliste (dizaines de milliers d'organisations, million d'arêtes collaboratives) et la double lecture contractuelle *vs* similarité. La valeur combine **pipeline traçable** et **UX d'exploration** ; les métriques doivent être interprétées avec prudence (biais de données, pas de causalité directe).

7.2 Perspectives

Multiplex temporel, embeddings neuronaux optionnels (dépendances déjà listées), RAG sur fiches projet, évaluation utilisateur, API en lecture seule sur les JSON, alignement Leiden/cdlib pour comparaison des partitions.



FIGURE 6 – Roadmap indicative.

Abstract (English)

This memorandum documents an end-to-end pipeline from European open funding data to interactive graph analytics : multiplex modeling, scalable network metrics (PageRank, community detection, brokerage proxies), and publication-grade visualizations—including a single-tabbed HTML hub aggregating country-level, institution-level, and bipartite demo views.

8 Bibliographie

- [1] L. LAMPORT, *LaTeX : A document preparation system*, Addison-Wesley, 2^e éd., 1994.
- [2] M. E. J. NEWMAN, *Networks : An Introduction*, Oxford University Press, 2010.
- [3] V. D. BLONDEL *et al.*, “Fast unfolding of communities in large networks,” *J. Stat. Mech.*, 2008.
- [4] S. FORTUNATO, “Community detection in graphs,” *Physics Reports*, vol. 486, no. 3–5, 2010.
- [5] A. A. HAGBERG, D. A. SCHULT, P. J. SWART, “Exploring network structure, dynamics, and function using NetworkX,” *Proc. SciPy*, 2008.

9 Webographie

- [1] Commission européenne, *CORDIS* — *Données de recherche de l'UE*.
<https://cordis.europa.eu/data>
- [2] OpenAlex, *API works*.
<https://api.openalex.org/>
- [3] OpenAIRE Graph API (optionnel).
<https://api.openaire.eu/>
- [4] NetworkX — bibliothèque Python pour graphes.
<https://networkx.org/>
- [5] scikit-learn — apprentissage automatique en Python.
<https://scikit-learn.org/>
- [6] Folium — cartes interactives.
<https://python-visualization.github.io/folium/>

A Cahier des charges

A.1 Contexte et périmètre

Mettre en œuvre une chaîne **open data** reliant financements européens (CORDIS), publications et concepts (OpenAlex, en partie optionnel OpenAIRE), pour produire des **graphes analysables** (collaboration explicite, proximité thématique, écarts / opportunités) et des **visualisations navigables**.

A.2 Exigences fonctionnelles

- **Ingestion** : téléchargement ou dépôt contrôlé des jeux bruts, paramètres de volumétrie (`--max-rows`, `--max-pages`).
- **Normalisation** : huit tables CSV UTF-8 sous `data/processed/` avec identifiants organisations stables.
- **Graphes** : export GEXF multiplexe explicite, couche thématique implicite, JSON d'analyse d'écarts ; métriques (centralités, communautés, contrainte).
- **Livrables utilisateur** : carte Folium HTML, fiches organisations, synthèses JSON (`metrics_summary.json`, `provenance`), et page `interactive_suite.html` pour accéder aux principales vues dans un seul navigateur.

A.3 Exigences non fonctionnelles

- **Reproductibilité** : scripts Python versionnés, environnement `venv` et `requirements.txt`.
- **Traçabilité** : rapport de provenance (`data_provenance_report.json`) après vérification.
- **Performance praticable** : limitation d'affichage navigateur tout en conservant les données complètes pour les analyses batch.

A.4 Critères de réception (indicatifs)

- Pipeline `run_pipeline.py` exécutable de bout en bout sur un échantillon documenté.
- Fichiers attendus présents : CSV normalisés, `collab_explicit.gexf`, `thematic_implicit` métriques, carte HTML, suite interactive.

B Exemple d'exécution du projet

B.1 Préparation de l'environnement

```
1 cd projet-graphe-recherche-eu
2 python3 -m venv env
3 source env/bin/activate    # Windows: env\Scripts\activate
4 pip install -r requirements.txt
```

B.2 Pipeline complet (extrait type)

```

1 python src/run_pipeline.py --max-rows 20000 --max-pages 5
2 # étapes détaillées possibles :
3 # python src/fetch_cordis.py --max-rows 40000
4 # python src/fetch_openalex.py --max-pages 8 --per-page 200
5 # python src/clean_normalize.py
6 # python src/build_graph.py
7 # python src/build_thematic_layer.py --threshold 0.35
8 # python src/gap_analysis.py --min-score 0.5
9 # python src/algorithms.py
10 # python src/visualize_folium.py --max-edges 400

```

B.3 Arborescence indicative après exécution

```

1 projet-graphe-recherche-eu/
2   data/raw/cordis/           # CSV CORDIS
3   data/raw/openalex/        # JSON œuvres
4   data/processed/           # 8 CSV normalisés
5   data/graphs/              # GEXF, JSON, HTML, org_profiles/,
6                               interactive_suite.html
7   src/                      # scripts du pipeline
8   rapport/premium/main.tex  # ce rapport (XeLaTeX)

```

B.4 Compilation du présent rapport

```

1 cd rapport/premium
2 latexmk -xelatex -interaction=nonstopmode main.tex

```

B.5 Lecture programmatique de la synthèse métriques

```

1 import json
2 from pathlib import Path
3
4 p = Path("data/graphs/metrics_summary.json")
5 summary = json.loads(p.read_text(encoding="utf-8"))
6 print(summary["collab_nodes"], summary["collab_edges"])

```

C Manuel utilisateur

C.1 Objectif

Permettre à un utilisateur de **régénérer les données, ouvrir la carte ou la suite HTML** et **interpréter** les couches sans relire l'intégralité du code.

C.2 Lancer le pipeline

— Racine du dépôt, environnement activé.

- **Commande recommandée** : `python src/run_pipeline.py` avec bornes adaptées à la machine.
- En cas d'échec sur une étape, enchaîner manuellement les scripts du README : `fetch_*`, `clean_normalize.py`, `construction des graphes`, `algorithms.py`, `visualisation`.

C.3 Carte interactive et suite multi-vues

- **Carte institutionnelle** : ouvrir `data/graphs/research_network_map_folium.html`.
- **Vue unique (recommandée pour présentation)** : ouvrir `data/graphs/interactive_suite.html`, puis sélectionner l'onglet souhaité (collaborations pays, réseau européen, démo bipartite multi-projets).
- **Recherche, zoom, bascule des couches** ; depuis une popup organisation, suivre le lien vers `org_profiles/` si généré.

C.4 Paramètres utiles

- `build_thematic_layer.py --threshold` : seuil de similarité cosinus sur le profil concepts (défaut 0,30).
- `gap_analysis.py --min-score` : filtre minimal sur le graphe thématique pour les opportunités.
- `visualize_folium.py --max-edges` : borne d'arêtes pour garder une carte fluide.

C.5 Dépannage (aperçu)

- **Fichier manquant** : relancer `clean_normalize.py` ou l'étape indiquée dans le message d'erreur.
- **Compilation LaTeX** : compiler avec **XeLaTeX** ; si les polices TeX Gyre ne sont pas résolues par le système, ajuster les chemins `fontpathTgyre` en tête de `main.tex`.
- **Dépendances lourdes** : utiliser `requirements-core.txt` sur Python récent si nécessaire.
- **iframes vides dans la suite** : ouvrir `interactive_suite.html` depuis le dossier `data/graphs/` (chemins relatifs vers les trois HTML).