



Graphes et Open Data

Université Paris Nanterre — Licence MIAGE APP

Analyse de réseaux de financement européen

Open data · multiplexe · métriques · visualisations

Nourane Hammouda

n° étudiante : 43017567

Encadré par Valentin Bouquet

Réalisation du 18 mars au 31 mai 2026

Soutenance orale le 22 mai 2026

Dépôt GitHub : <https://github.com/nourane-hammouda/OpenEUREsearch-Graph>

Remerciements

La réalisation de ce projet n'aurait pas été possible sans le soutien et les conseils des personnes que je souhaite ici remercier sincèrement.

Je tiens tout d'abord à exprimer ma gratitude à Monsieur **Valentin Bouquet**, enseignant du module *Graphes et Open Data* pour son accompagnement tout au long du projet. Ses remarques et ses conseils m'ont permis de faire évoluer progressivement mon travail depuis une première idée centrée sur l'analyse de données ouvertes jusqu'à une application plus complète intégrant la théorie des graphes, le traitement de données, la cartographie interactive et des livrables HTML reproductibles (pipeline batch, graphes, métriques et suite de visualisation). Les échanges réalisés pendant les séances de suivi m'ont également aidé à prendre du recul sur mes choix techniques, notamment sur la construction du graphe, la pertinence des arêtes, les limites des données utilisées et les pistes d'amélioration possibles.

Je souhaite aussi remercier mes camarades de promotion pour les échanges et les discussions que nous avons pu avoir tout au long du semestre. Même si ce projet a été réalisé individuellement, ces échanges ont été utiles pour garder une dynamique de travail, partager certaines difficultés et prendre du recul sur les choix effectués.

Je remercie également l'**Université Paris Nanterre** pour le cadre de formation proposé au sein de la MIAGE. Ce projet m'a permis de mobiliser plusieurs compétences acquises durant mon parcours, en particulier en programmation, en bases de données, en systèmes d'information, en analyse de données et en développement applicatif. Il a aussi été l'occasion de relier des aspects techniques à une problématique concrète, territoriale et sociale, ce qui correspond pleinement à l'esprit de la formation.

Enfin, je remercie toutes les personnes qui ont contribué, directement ou indirectement, à l'avancement de ce projet. Cette expérience a représenté un travail exigeant mais très formateur. Elle m'a permis de progresser dans ma manière de concevoir, tester, corriger et améliorer une application complète, tout en développant une démarche plus rigoureuse et plus autonome.

Table des matières

Remerciements	1
1 Introduction	5
1.1 Contexte	5
1.2 Problématique	5
1.3 Objectifs	5
2 Présentation du projet	6
2.1 Contexte général et origine du sujet	6
2.2 Objectifs du projet	6
2.3 Fonctionnalités principales	6
2.4 Place du projet dans une démarche MIAGE	6
3 Environnement de travail et technologies utilisées	6
3.1 Organisation générale de l'environnement	7
3.2 Bibliothèques obligatoires du module	7
3.3 Technologies complémentaires ajoutées au projet	7
3.4 Structure fonctionnelle de l'application	7
3.5 Parcours utilisateur détaillé	8
3.6 Organisation des fichiers et logique modulaire	8
4 Conception du projet	8
4.1 Architecture générale	9
4.2 Conception des données	9
4.3 Conception du modèle de graphe	9
4.4 Conception de l'interface utilisateur	10
4.5 Scénarios d'usage retenus	10
4.6 Présentation détaillée des écrans principaux	11
4.7 Manuel d'utilisation synthétique	14
4.8 Conception du stockage et persistance des artefacts	14

5	Implémentation et réalisation	15
5.1	Traitement et nettoyage des données	15
5.2	Normalisation et identité	15
5.3	Développement du pipeline Python orchestré	16
5.4	Visualisation cartographique avec Folium	16
5.5	Calculs de métriques et priorisation des écarts	16
5.6	Formules des métriques réseau	17
5.7	Exports JSON métier	18
5.8	Approche détaillée de l'enrichissement OpenAlex	18
5.9	Exports graphes, JSON et vues complémentaires	18
6	Tests, validations et gestion des régressions	18
6.1	Logique générale de validation	18
6.2	Tests sur les données	19
6.3	Tests sur l'interface	19
6.4	Performance et stabilité	19
6.5	Tableau de validation fonctionnelle	19
7	Résultats obtenus	19
7.1	Un prototype complet d'analyse de réseaux européens	19
7.2	Apports techniques	20
7.3	Bilan de la progression	20
7.4	Lecture analytique des résultats	20
7.5	Apport pour l'aide à la décision	21
8	Difficultés rencontrées et limites du projet	21
8.1	Difficultés liées aux données	21
8.2	Difficultés liées à l'acquisition et à l'échelle	21
8.3	Limites de la modélisation par graphe	21
8.4	Difficultés d'intégration entre les briques techniques	22
8.5	Limites techniques et statut du prototype	22

9 Perspectives d'amélioration	22
9.1 Amélioration de la qualité des données	22
9.2 Amélioration des modèles et des paramètres	22
9.3 Amélioration technique et ergonomique	22
9.4 Mise en production et cadre juridique	22
10 Conclusion	23
Bibliographie	24
11 Webographie	25
12 Annexes	26
12.1 Journal d'activité synthétique	26
12.2 Flux technique simplifié	26
12.3 Annexe technique : commandes locales utiles	26
12.4 Ouverture des vues interactives	27
12.5 Paramètres fréquemment ajustés	27
12.6 Index des figures et tables internes au rapport	27
12.7 Arborescence du dépôt	27

1 Introduction

1.1 Contexte

Les financements européens laissent des traces relationnelles exploitables : co-participations, montants, rattachements institutionnels et, via des référentiels ouverts, des liens vers publications et concepts thématiques. Les portails **CORDIS** et **OpenAlex** rendent une partie de ces signaux *reproductibles* ; le défi est de les normaliser, de les modéliser en graphe et d'en extraire des indicateurs interprétables sans sur-interpréter la causalité.

Du point de vue **système d'information**, on distingue le fonctionnel métier (qui finance quoi, qui collabore) du fonctionnel analytique (centralités, communautés, priorisation des écarts). Le prototype sépare ces niveaux en artefacts CSV/JSON et pages HTML pour faciliter l'audit.

Graphe de collaboration explicite

On note $G_{\text{ex}} = (V, E)$ le graphe **sommets organismes**, avec une arête $\{u, v\}$ dès que u et v co-financent au moins un projet européen commun ; le poids entier compte les projets en commun (`edges_org_org_explicit.csv`).

1.2 Problématique

Deux lectures se complètent : (i) la **collaboration observée** (CORDIS) ; (ii) la **proximité thématique** (OpenAlex/concepts). La question centrale : *qui pourrait collaborer* parmi des acteurs proches scientifiquement mais peu connectés contractuellement, sans transformer l'outil en décision automatique.

1.3 Objectifs

- construire une chaîne **open data** → **tables** → **graphes** → **métriques** → **visualisations** reproductible ;
- comparer G_{ex} et G_{th} (cosinus sur concepts) ;
- livrer des sorties **navigables** (`interactive_suite.html`, JSON, fiches organisation).

Insight. Fil conducteur : pipeline **batch** Python, pages HTML statiques (pas de serveur Flask ni de SGBD obligatoire dans le périmètre livré).

2 Présentation du projet

2.1 Contexte général et origine du sujet

Le travail s'inscrit dans le module *Graphes et Open Data* (Université Paris Nanterre, MIAGE). Le périmètre métier est le **réseau institutionnel européen** (Horizon 2020, Horizon Europe) décrit par CORDIS, enrichi par des publications OpenAlex filtrées sur le financement Commission européenne. Le dépôt <https://github.com/nourane-hammouda/OpenEUREsearch-Graph> matérialise une réponse technique complète au cahier des charges du module.

2.2 Objectifs du projet

Les objectifs opérationnels rejoignent la problématique de l'introduction : produire des **faits relationnels versionnables**, calculer des **écarts thématiques/explicites**, prioriser des **pistes** via le score π , et permettre une **exploration interactive** sans dépendre d'une stack web lourde.

2.3 Fonctionnalités principales

- ingestion paramétrable (`--max-rows`, `--max-pages`);
- huit tables CSV sous `data/processed/`, identifiant `org_id`;
- graphes `collab_explicit.gexf`, `thematic_implicit.gexf`;
- métriques (PageRank, Louvain, betweenness échantillonnée, Burt) et `gap_analysis_top.json`;
- hub `interactive_suite.html`, cartes Folium, démo biparti, vue concepts, `org_profiles/`.

2.4 Place du projet dans une démarche MIAGE

Synthèse SI (provenance, qualité), **modèle de données** (schéma relationnel plat), **algorithmique graphe**, **livrables utilisateur**. Les jeux sont publics; le pipeline n'a pas vocation au profilage de personnes. Les classements π restent des hypothèses à valider par un expert métier.

3 Environnement de travail et technologies utilisées

3.1 Organisation générale de l’environnement

Développement sur **macOS/Linux**, Python 3, environnement virtuel (`python3 -m venv env`). Orchestration par `src/run_pipeline.py`. Rédaction du rapport en **XeLaTeX** (polices TeX Gyre). Les livrables HTML s’ouvrent localement dans un navigateur ; `data/graphs/` doit rester la racine relative des iframes.

3.2 Bibliothèques obligatoires du module

Le cœur du module *Graphes et Open Data* est couvert par les composants du tableau 1.

TABLE 1 – Bibliothèques au cœur du module (graphes et données).

Composant	Rôle dans le projet
pandas	/ ETL CSV/JSON, matrices creuses org×concept.
NumPy	
NetworkX	GEXF, PageRank, betweenness, Burt, Louvain [5, 3].
requests	/ Téléchargement CORDIS et API OpenAlex.
httpx	

3.3 Technologies complémentaires ajoutées au projet

TABLE 2 – Technologies complémentaires (visualisation et extensions).

Composant	Rôle
Folium / Leaflet	Cartes européennes et macro pays.
Pyvis	Démo biparti et vue concepts (<code>map_concept_networkx_view.html</code>).
scikit-learn	TF-IDF (<code>dynamic_opportunities.json</code>).
Optionnel (<code>requirements.txt</code>) : sentence-transformers, torch, faiss, leidenalg — hors flux minimal.	

Assistance IA. **Gemini CLI** (`context/GEMINI_CONTEXT.md`) a aidé au développement et à la documentation. **Aucun LLM ne calcule π , le cosinus ni les centralités.**

3.4 Structure fonctionnelle de l’application

Le prototype suit une architecture **ETL batch** (figure 1) : pas d’application Flask ni de base PostgreSQL dans la livraison ; la « structure applicative » est la chaîne de scripts et les artefacts qu’elle régénère.



FIGURE 1 – Chaîne fonctionnelle (batch + livrables HTML).

3.5 Parcours utilisateur détaillé

1. Exécuter `run_pipeline.py` (ou les scripts étape par étape).
2. Consulter `data/graphs/data_provenance_report.json` et les CSV `processed/`.
3. Ouvrir `interactive_suite.html` depuis `data/graphs/`.
4. Onglet **pays** : asymétries transnationales.
5. Onglet **réseau** : zoom, filtres, couches collaboration / opportunités.
6. Popup Folium → fiche `org_profiles/` si disponible.
7. Onglet **biparti** : cas CNRS/CEA (`vis-network`).
8. Optionnel : `map_concept_networkx_view.html` (concepts).

3.6 Organisation des fichiers et logique modulaire

Le dépôt sépare `src/`, `data/raw`, `data/processed`, `data/graphs`. Chaque script est relançable isolément. Le tableau 3 résume l’ordonnancement ; `data_provenance_report.json` consolide la traçabilité.

TABLE 3 – Ordonnancement des scripts (`src/`).

Phase	Script	Artefacts
Acquisition	<code>fetch_cordis.py</code> , <code>fetch_openalex.py</code>	brut CORDIS, JSON OpenAlex
Normalisation	<code>clean_normalize.py</code>	8 CSV
Multiplexe	<code>build_graph.py</code>	<code>collab_explicit.gexf</code>
Thème	<code>build_thematic_layer.py</code>	<code>thematic_implicit.gexf</code>
Écarts	<code>gap_analysis.py</code>	<code>gap_analysis_top.json</code>
Algos	<code>algorithms.py</code>	<code>organization_metrics.json</code>
Contrôles	<code>verify_data_sources.py</code> , <code>temporal_analysis.py</code>	provenance, temporel
Viz	<code>visualize_folium.py</code>	Folium, <code>interactive_suite.html</code>
Explor.	<code>build_map_concept_networkx.py</code>	<code>map_concept_networkx_view.html</code>

4 Conception du projet

4.1 Architecture générale

Schéma ETL : sources ouvertes → schéma relationnel plat → graphes multiplexes → métriques → HTML. Les calculs lourds restent batch ; le navigateur ne fait qu'interpréter des fichiers pré-calculés.

4.2 Conception des données

Les huit fichiers constituent un **schéma relationnel plat** lisible hors SGBD. Le tableau 4 présente brièvement chaque jeu ; ils sont interconnectés via `org_id`, `project_id` et identifiants d'œuvre/concept.

TABLE 4 – Jeux CSV normalisés (`data/processed/`) — exemplaire documenté (tailles disque et volumétrie indicative).

Fichier	Taille	Lignes	Colonnes clés et rôle
<code>organizations.csv</code>	5,6 Mo	41 707	<code>org_id</code> , <code>org_name</code> , <code>country</code> , <code>city</code> , <code>org_type</code> , <code>budget_total_received</code> , <code>nb_projects</code> , <code>latitude</code> , <code>longitude</code> — nœuds organisations.
<code>projects.csv</code>	5,2 Mo	34 136	<code>project_id</code> , <code>project_title</code> , <code>program</code> , <code>dates</code> , <code>topic_label</code> , <code>project_budget_eur</code> .
<code>publications.csv</code>	36 Ko	201	<code>publication_id</code> , <code>doi</code> , <code>year</code> , <code>title</code> , <code>journal</code> — échantillon OpenAlex (filtre financeur CE).
<code>concepts.csv</code>	180 Ko	2 844	<code>publication_id</code> , <code>concept_label</code> , <code>concept_score</code> .
<code>edges_org_project.csv</code>	7,7 Mo	178 559	<code>source_org_id</code> , <code>target_project_id</code> , <code>weight_eur</code> — biparti financement.
<code>edges_org_org_explicit.csv</code>	67 Mo	1 145 156	<code>org_a</code> , <code>org_b</code> , <code>weight_common_projects</code> — projection G_{ex} .
<code>edges_org_publication.csv</code>	29 Ko	425	<code>source_org_id</code> , <code>publication_id</code> — appariement lexical des noms.
<code>edges_org_concept.csv</code>	317 Ko	4 726	<code>source_org_id</code> , <code>concept_label</code> , <code>weight</code> — profils pour G_{th} .

Bruts ingérés (`data/raw/`). `fetch_cordis.py` télécharge depuis <https://cordis.europa.eu/data> les jeux `h2020_*` et `he_*` (projets et organisations, CSV ou ZIP, séparateur `;`) vers `data/raw/cordis/`. `fetch_openalex.py` interroge <https://api.openalex.org/works> avec le filtre `awards.funder_id:F4320332161` (Commission européenne) et persiste `works_ec_funded.json`. OpenAIRE reste optionnel (`fetch_openaire.py`).

L'identifiant `org_id` préfère les identifiants CORDIS (PIC) ; sinon empreinte `nom|ville|type` puis hachage SHA-1 tronqué, pour limiter les collisions silencieuses lors des rapprochements itératifs.

4.3 Conception du modèle de graphe

G_{ex} projete les co-projets en Org–Org (poids = # projets communs). Le fichier `collab_explicit.gexf` inclut aussi projets et publications (multiplexe étendu, ≈ 312 Mo sur l'exemplaire). G_{th} résulte du cosinus entre profils `org`×`concept` normalisés (norme euclidienne unitaire par ligne) avec seuil θ (défaut 0,30, option --

threshold) :

$$\cos(u, v) = \frac{\mathbf{p}_u \cdot \mathbf{p}_v}{\|\mathbf{p}_u\| \|\mathbf{p}_v\|}, \quad \text{arête thématique si } \cos(u, v) \geq \theta. \quad (1)$$

Une **opportunité** est une paire forte en G_{th} absente de G_{ex} et passant le seuil métier s_{min} (`--min-score`, défaut 0,40 dans `gap_analysis.py`) :

$$(u, v) \in G_{th} \wedge (u, v) \notin G_{ex} \wedge s \geq s_{min}. \quad (2)$$




FIGURE 2 – Bipartition financement et projection explicite (schéma).

Cadrage théorique. Le projet mobilise les réseaux complexes [2] : PageRank et betweenness sur G_{ex} , Louvain [3], Burt sur G_{th} , lecture multiplexe [4].

4.4 Conception de l'interface utilisateur

Le projet ne déploie pas de serveur applicatif : les pages sont des artefacts statiques régénérés par le pipeline. Le **hub** `interactive_suite.html` regroupe trois visualisations en iframes (chargement paresseux des onglets 2 et 3).

Lecture « quatre vues » en soutenance. En présentation, on distingue souvent (i) collaborations observées, (ii) couche opportunités, (iii) macro pays, (iv) cas biparti : (i) et (ii) correspondent aux **couches et filtres** de la carte réseau ; (iii) et (iv) sont les onglets dédiés du hub. La carte concepts sert d'illustration complémentaire du volume thématique.

`visualize_folium.py` produit également `research_network_map_folium.html`, alimente `dynamic_opportunities.json` (TF-IDF sur corpus de titres/topics par organisation) et peut régénérer `interactive_suite.html`. Le script `build_map_concept_networkx.py` alimente la vue concepts.

4.5 Scénarios d'usage retenus

— **Analyste open data** : vérifier volumes, provenance, cohérence des jointures.

TABLE 5 – Interfaces utilisateur (data/graphs/).

Vue		Fichier / hash	Rôle
Collaborations pays	par	country_collaborations_map.html (#carte-collaborations)	Carte Folium macro — liens transnationaux entre pays institutionnels ($\approx 4,8$ Mo).
Réseau européen		research_network_map_folium.html (#reseau-recherche)	Établissements géolocalisés, filtres, popups; couches collaboration explicite et opportunités thématiques ($\approx 8,1$ Mo).
Démo biparti		demo_multi_project_pair.html (#demo-multi-projets)	Graphe <i>vis-network</i> organisations↔projets (ex. CNRS/-CEA, ≈ 154 Ko).
Réseau concepts		map_concept_networkx_view.html	Exploration Pyvis du graphe concepts (hairball, hors hub, $\approx 2,6$ Mo).
Fiches organisation		org_profiles/*.html	Pages détail (budgets, top projets/collaborations/opportunités, métriques) depuis popups Folium.

- **Chargé de veille scientifique** : parcourir le top π et confronter à des stratégies d'établissement.
- **Soutenance / démonstration** : suite interactive, cas biparti, lecture macro pays.
- **Reproductibilité** : relancer le pipeline avec `--max-rows` réduit puis `run` complet.

4.6 Présentation détaillée des écrans principaux

Protocole. Les figures 3 à 7 suivent l'ordre du hub `interactive_suite.html` (pays, réseau en deux lectures, biparti, concepts). Chaque capture figure sous son paragraphe. Les tableaux 10 et 8 restent la référence chiffrée.

Onglet 1 — Collaborations transnationales. `country_collaborations_map.html` — carte macro (173 pays, liens pays–pays, cercles selon le budget).




FIGURE 3 – Collaborations transnationales. Agrégation par pays, liens orange (projets cumulés), barre latérale KPI.

Onglet 2a — Réseau, collaboration explicite. `research_network_map_folium.html` — couches *Bulles*, *Liens de collaboration* (rouge, G_{ex}), *Organisations*; opportunités désactivées.




FIGURE 4 – Réseau européen, arêtes rouges (G_{ex}). Top 2 000 org. classées par PageRank collaboratif.

Onglet 2b — Réseau, opportunités thématiques. Même carte — couche *Opportunités* activée (liens violets). Lecture liée au score π (éq. (3)).




FIGURE 5 — Même vue Folium avec opportunités thématiques (arêtes violettes, +110 org. de contexte).

Onglet 3 — Démo bipartite. `demo_multi_project_pair.html` — *vis-network*, exemple CNRS/CEA.

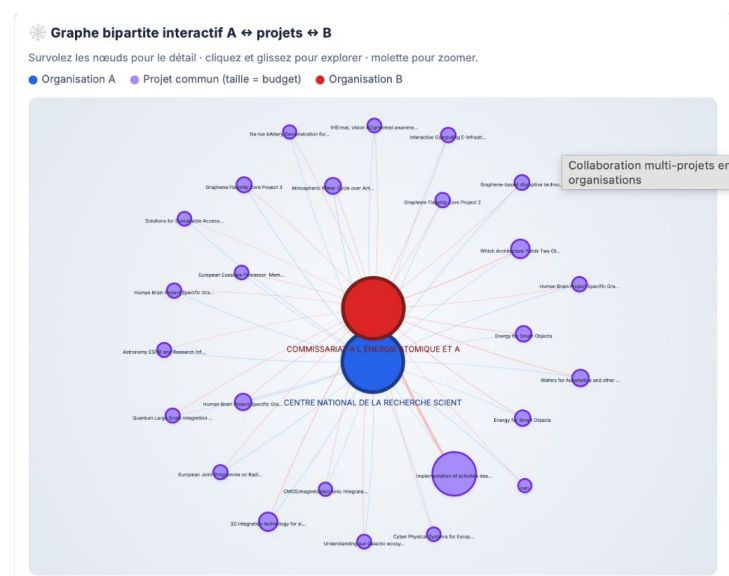


FIGURE 6 — Bipartition org. / projets — CNRS (bleu), CEA (rouge), projets communs (violet).

Complément — Réseau de concepts. [map_concept_networkx_view.html](#) (script `build_map_concept_networkx.py`) — hairball Pyvis, hors hub.




FIGURE 7 – Graphe concepts (noyau dense + anneau isolé), complément à G_{th} .

4.7 Manuel d'utilisation synthétique

1. `source env/bin/activate`
2. `python src/run_pipeline.py --max-rows 40000 --max-pages 8`
3. Ouvrir `data/graphs/interactive_suite.html` en conservant `data/graphs/` comme racine des URLs relatives.
4. Naviguer les onglets pays / réseau / biparti; activer les couches sur la carte réseau.
5. Exporter ou relire `gap_analysis_top.json` pour une liste priorisée hors navigateur.

4.8 Conception du stockage et persistance des artefacts

Le projet **ne mobilise pas PostgreSQL** dans la livraison : la persistance repose sur CSV (`processed/`), GEXF/GraphML (`graphs/`), JSON métier et HTML statiques. Cette conception facilite le versionnement Git, l'audit et la reprise sur incident, au prix d'absence de requêtage SQL temps réel.

5 Implémentation et réalisation

5.1 Traitement et nettoyage des données

Acquisition. `fetch_cordis.py` télécharge les exportations tabulaires CORDIS pertinentes au périmètre **Horizon 2020** et **Horizon Europe** lorsque ces jeux sont publiés sur le portail <https://cordis.europa.eu/data>. Le parseur anticipe séparateur ; et BOM UTF-8, ainsi que plusieurs variantes de noms de colonnes (voir logique métier décrite dans le README du dépôt). Lorsque l'argument `--max-rows` est invoqué, des fichiers "*trimmed*" permettent d'encoder des jeux représentatifs tout en gardant une empreinte mémoire raisonnable.

`fetch_openalex.py` interroge l'endpoint `/works` d'OpenAlex avec un curseur opaque afin de parcourir le corpus page par page (`--per-page`, `--max-pages`). Le jeu est restreint aux œuvres pour lesquelles le financeur Commission européenne est attesté dans les métadonnées d'award. Cette restriction limite analytiquement le corpus mais aligne celui-ci sur une lecture *funding-first* comparable à CORDIS. Enfin, `fetch_openaire.py` peut être invoquée via `run_pipeline.py--include-openaire` pour des croisements optionnels hors flux minimal.

Sur un poste de développement, `--max-rows` et `--max-pages` permettent de valider la chaîne sur un sous-échantillon avant un passage complet. Cette souplesse est essentielle pour tester les jointures et la cohérence des exports sans saturer la mémoire.

5.2 Normalisation et identité

`clean_normalize.py` mappe les colonnes, convertit les montants, génère paires collaboratives et liaisons financement. Appariement OpenAlex sur normalisation stricte du nom d'organisation (risque d'homonymes).

Logique de projection des co-projets. Pour chaque projet comportant au moins deux organisations financées, le script engendre l'ensemble des paires distinctes et incrémente le poids `weight_common_projects`. La table `edges_org_project.csv` conserve en parallèle le détail *org* → *projet* avec un poids monétaire agrégé (contribution nette UE lorsque la colonne est disponible), ce qui permet de reconstruire à la fois le graphe biparti et sa projection unimodale.

Profils concepts. Les scores OpenAlex attachés aux concepts sont sommés par organisation sur l'ensemble des publications appariées ; la matrice creuse *org*×*concept*

sert ensuite de base à la normalisation ligne par ligne (norme euclidienne) avant similarité cosinus inter-organisations dans `build_thematic_layer.py`.

5.3 Développement du pipeline Python orchestré

`run_pipeline.py` enchaîne fetch, normalisation, graphes, écarts, métriques, contrôles et visualisation. `build_graph.py` matérialise le multiplexe et la projection G_{ex} . Chaque étape reste exécutable seule pour le débogage.

5.4 Visualisation cartographique avec Folium

`visualize_folium.py` génère `research_network_map_folium.html`, `country_collaborations_map.html`, alimente `dynamic_opportunities.json` (TF-IDF) et régénère `interactive_suite.html`. Les filtres `--max-edges` préservent la fluidité du DOM.

5.5 Calculs de métriques et priorisation des écarts

`build_graph.py`, `build_thematic_layer.py` et `gap_analysis.py` chaînent multiplexe, G_{th} et priorisation des écarts.

Priorisation π et métriques. Centralités et Louvain via NetworkX; betweenness bornée ou échantillonnée à grande échelle. Le bonus `broker` combine un signal de betweenness sur G_{ex} et une contrainte de Burt sur G_{th} pour signaler des positions articulatrices *potentielles* — à interpréter avec prudence car la couche thématique est partielle. Score agrégé (pondérations métier) :

$$\pi = 0,60s + 0,15b_{\text{broker}} + 0,10c + 0,10t + 0,05\text{balance}, \quad (3)$$

avec seuils d'étiquettes sur π et export borné `gap_analysis_top.json`.

TABLE 6 – Paramètres de filtrage thématique (distincts du score π).

Paramètre	Défaut	Rôle
<code>--threshold</code> (θ)	0,30	Crée une arête dans G_{th} si $\cos \geq \theta$.
<code>--min-score</code> ($s_{\min}$)	0,40	Exclut les paires opportunité dont le cosinus s est trop faible.

Séquence de filtrage. Une arête candidate du graphe thématique doit d'abord satisfaire θ (construction de G_{th}), puis le score thématique s de la paire doit dépasser `--min-score` (défaut 0,40, distinct de θ) avant export dans `gap_analysis_top.json`.

TABLE 7 – Correspondance indicative score $\rightarrow$ étiquette (implémentation `gap_analysis.py`).

Condition sur π	Libellé
$\pi \geq 0,80$	Très forte
$\pi \geq 0,65$	Forte
$\pi \geq 0,55$	Intermédiaire
sinon	À surveiller

Les paires déjà présentes dans `edges_org_org_explicit.csv` sont exclues : une collaboration CORDIS avérée n'est pas requalifiée en « opportunité ». L'export JSON conserve au plus 3 000 paires triées par π .

Interprétation des pondérations π . Le coefficient 0,60 sur s signifie que 60 % du score de priorisation provient de la proximité thématique (cosinus), et non que le cosinus vaut 0,60. Les 40 % restants affinent le classement (broker, diversité pays/-types, équilibre de taille) sans écraser le signal scientifique central du projet.

5.6 Formules des métriques réseau

Les centralités et communautés sont calculées sur le sous-graphe `organization` de G_{ex} (poids `weight\_common\_projects`), sauf la contrainte de Burt sur G_{th} .

PageRank (influence sur collaborations observées).

$$PR(v) = \frac{1-d}{n} + d \sum_{u \rightarrow v} \frac{PR(u)}{\deg^+(u)}, \quad d \approx 0,85. \quad (4)$$

Betweenness (positions de passage, approximée).

$$C_B(v) = \sum_{s \neq v \neq t} \frac{\sigma_{st}(v)}{\sigma_{st}}, \quad (5)$$

où σ_{st} est le nombre de plus courts chemins entre s et t ; l'implémentation utilise un échantillonnage $k = \min(500, |V|)$ pour contenir le coût sur G_{ex} .

Contrainte de Burt et rôle broker. Sur G_{th} , NetworkX calcule la contrainte structurelle C_i de Burt (signal de redondance des voisinages). Le bonus `broker` vaut 1 si l'organisation combine une betweenness strictement positive sur G_{ex} et un rang favorable sur la contrainte thématique (top 30 % des valeurs positives).

Louvain (communautés). La méthode maximise la modularité Q pour partitionner G_{ex} et G_{th} en communautés indicatives [3] (graine fixe pour reproductibilité).

5.7 Exports JSON métier

TABLE 8 – Principaux livrables structurés (data/graphs/).

Fichier	Intérêt
metrics_summary.json	Synthèse (# nœuds/arêtes, partitions Louvain, top PageRank).
organization_metrics.json	Métriques par org_id (PageRank, betweenness, Burt, communautés).
gap_analysis_top.json	Jusqu'à 3 000 paires (π , label, métadonnées pays/types).
dynamic_opportunities.json	Couche opportunités TF-IDF pour la carte Folium.
data_provenance_report.json	Traçabilité, tailles sources, contrôles d'intégrité.
display_filter_report.json	Paramètres de filtrage affichage carte.
temporal_summary.csv	Agrégats temporels (temporal_analysis.py).

5.8 Approche détaillée de l'enrichissement OpenAlex

Les publications filtrées (financier CE) sont appariées aux organisations CORDIS par nom normalisé. Les concepts et scores alimentent `edges_org_concept.csv`, puis la matrice creuse et le cosinus dans `build_thematic_layer.py`. La couverture reste partielle (200 œuvres sur l'exemple).

5.9 Exports graphes, JSON et vues complémentaires

`algorithms.py` écrit les centralités et communautés. `build_map_concept_networkx.py` produit la vue concepts. Les JSON métier sont récapitulés tableau 8; `verify_data_sources.py` et `temporal_analysis.py` complètent le run.

6 Tests, validations et gestion des régressions

6.1 Logique générale de validation

Pas de batterie PyTest systématique : validation par **rejouabilité** du pipeline, contrôles de structure et recette manuelle des HTML.

6.2 Tests sur les données

Une exécution type vérifie présence des CSV, GEXF, JSON et cartes. Bornes de volumétrie (`--max-rows`, `--max-pages`) permettent des runs de contrôle rapides.

6.3 Tests sur l'interface

En complément des contrôles automatisables, trois scénarios sont rejoués avant une livraison interne : (1) ouverture de `interactive_suite.html` avec vérification du chargement des trois iframes ; (2) inspection d'un marqueur Folium (popup, lien vers fiche `org_profiles/` si présent) ; (3) contrôle de cohérence entre le nombre de paires listées dans `gap_analysis_top.json` et un échantillon tiré manuellement dans `edges_org_org_explicit.csv` pour vérifier l'exclusion des doublons explicites.

6.4 Performance et stabilité

DOM lourd des cartes et `betweenness` coûteuse : atténués par filtrage et approximations. Paquet `requirements-core.txt` si conflits avec dépendances étendues.

6.5 Tableau de validation fonctionnelle

TABLE 9 – Contrôles rapides réalisés lors des itérations de développement.

Axe	Indicateur / action
Présence	Post-pipeline : existence des 8 CSV, GEXF, JSON synthèse.
Cohérence	Comptages croisés (nb org = cardinal unique des sommets attendus).
Qualité	Part de géolocalisation renseignée, budgets non négatifs.
Interface	Test manuel zoom / popups / iframes suite HTML.

7 Résultats obtenus

7.1 Un prototype complet d'analyse de réseaux européens

Le tableau 10 résume un exemplaire mesuré lors de la rédaction ; les ordres de grandeur **dépendent** des paramètres et du snapshot source.

TABLE 10 – Ordres de grandeur (exemplaire local documenté).

Mesure	Valeur
Organisations (<code>organizations.csv</code>)	41 706
Projets (<code>projects.csv</code>)	34 135
Financement org→projet (<code>edges_org_project.csv</code>)	178 558
Paires collaborations explicites (<code>edges_org_org_explicit.csv</code>)	1 145 155
Œuvres OpenAlex (<code>publications.csv</code>)	200
<code>collab_explicit.gexf</code> (taille disque)	≈ 312 Mo
<code>thematic_implicit.gexf</code>	≈ 825 Ko
$ V , E $ dans G_{th} (GEXF)	160 / 2 737
Paires exportées (<code>gap_analysis_top.json</code>)	1 674 (top 3 000 max.)
Budgets agrégés (<code>budget_total_received</code>)	≈ 68 G€




FIGURE 8 – Ordres de grandeur sur l'exemplaire (échelle logarithmique).

7.2 Apports techniques

Le dépôt démontre une chaîne industrielle plausible open data → graphes → métriques → HTML, avec séparation faits relationnels / couche de communication (audit, reprise).

7.3 Bilan de la progression

Le projet est passé d'une ingestion tabulaire à un multiplexe exploitable, puis à des vues interactives intégrées dans `interactive_suite.html`, en gardant un fil conducteur : les opportunités de collaboration comme hypothèses, non comme décisions.

7.4 Lecture analytique des résultats

Alerte méthodo. Les listes d'« opportunités » restent des **hypothèses de travail** exploitant l'écart $G_{th} \setminus G_{ex}$ sur données incomplètes ; toute priorisation π doit être relue par un expert métier avant action.

Le multiplexe confronte un graphe massif de collaboration et une couche thématique très filtrée ; les opportunités reflètent un *écart de couverture observé* dans les données ouvertes, non une recommandation prescriptive.

7.5 Apport pour l'aide à la décision

Quatre constats guident la lecture : (1) le volume d'arêtes collaboratives traduit une **densification par les programmes** plutôt qu'une vision exhaustive de toutes les interactions scientifiques ; (2) OpenAlex n'apporte ici qu'un **échantillon de publications** liées au filtre financeur : le profil conceptuel reste partiel ; (3) les partitions Louvain sur G_{ex} servent de **repères exploratoires** — elles changent avec le seuil de filtrage et la pondération ; (4) le fichier `gap_analysis_top.json` fournit une **liste priorisée d'hypothèses de mise en relation** à confronter à des sources externes (appels à projets, stratégies d'établissement). Le prototype illustre en outre comment un service d'analyse peut séparer la **construction de faits relationnels** (tables et graphes versionnables) de la **couche de communication** (HTML), ce qui facilite l'audit et la reprise sur incident.

8 Difficultés rencontrées et limites du projet

8.1 Difficultés liées aux données

Hétérogénéité CORDIS, identifiants lacunaires, appariement lexical OpenAlex (homonymies). Montants agrégés indicatifs. Volume `edges_org_org_explicit.csv` (67 Mo) contraignant en RAM.

8.2 Difficultés liées à l'acquisition et à l'échelle

Téléchargements CORDIS volumineux, pagination OpenAlex, temps de calcul de la betweenness et du rendu Folium sur graphes denses.

8.3 Limites de la modélisation par graphe

Cosinus thématique $\neq$ complémentarité métier. θ et `min-score` orientent l'espace exploré. Similarité $\neq$ collaboration garantie.

8.4 Difficultés d'intégration entre les briques techniques

Multiples formats (CSV, GEXF, JSON, HTML), chemins relatifs des iframes, synchronisation des paramètres de filtrage entre scripts et cartes.

8.5 Limites techniques et statut du prototype

Prototype de recherche/formation : pas de SLA, pas de multi-utilisateurs, pas de moteur de recherche full-text sur les fiches. Les dépendances lourdes (torch, etc.) restent optionnelles.

9 Perspectives d'amélioration

9.1 Amélioration de la qualité des données

Identifiants ROR/PIC systématiques, enrichissement OpenAIRE, data card et journal de qualité par run.

9.2 Amélioration des modèles et des paramètres

Analyse de sensibilité sur θ , $s_{\min}$ et les pondérations π ; validation avec experts métier ; complémentarité au-delà du cosinus.

9.3 Amélioration technique et ergonomique

API lecture seule sur JSON, intégration de la vue concepts dans le hub, tests utilisateurs, Leiden pour comparer les partitions.

9.4 Mise en production et cadre juridique

Hébergement statique des HTML, documentation RGPD renforcée, gouvernance des mises à jour CORDIS/OpenAlex.

10 Conclusion

Le dépôt illustre une boucle industrielle plausible **open data** → **schéma relationnel** → **graphes multiplexes** → **métriques réseaux** → **restitution géographique et narrative** [2, 4], alignée avec les compétences MIAGE autour du SI évolutif, de la qualité de données et de la valorisation par la visualisation.

Les apports observés se déclinent ainsi :

- **Traçabilité** : chaque niveau produit des artefacts vérifiables (CSV versionnés, JSON de synthèse, provenance) ;
- **Dualité multiplexe** : mise en tension explicite de la vérité contractuelle CORDIS et d'une couche indicative de similarité concepts ;
- **Expérience utilisateur** : passerelle via Folium/HTML entre analyste et carte interactive sans déployer d'architecture serveur obligatoire.

L'enjeu final reste l'**interprétation** des écarts thématiques/explicites, plus que la précision asymptotique d'un score ponctuel. Les cinq captures de la section 4.6 (ordre du hub interactif) rappellent que les graphes ainsi produits constituent des *instruments de dialogue* aussi bien que des modèles.

Bibliographie

-
- [1] L. LAMPORT, *L^AT_EX : A document preparation system*, Addison-Wesley, 2^e éd., 1994.
 - [2] M. E. J. NEWMAN, *Networks : An Introduction*, Oxford University Press, 2010.
 - [3] V. D. BLONDEL *et al.*, "Fast unfolding of communities in large networks," *J. Stat. Mech.*, 2008.
 - [4] S. FORTUNATO, "Community detection in graphs," *Physics Reports*, vol. 486, no. 3–5, 2010.
 - [5] A. A. HAGBERG, D. A. SCHULT, P. J. SWART, "Exploring network structure, dynamics, and function using NetworkX," *Proc. SciPy*, 2008.

11 Webographie

- [1] Commission européenne, *CORDIS — Données de recherche de l'UE*.
<https://cordis.europa.eu/data>
- [2] OpenAlex, *API works*.
<https://api.openalex.org/>
- [3] OpenAIRE Graph API (optionnel).
<https://api.openaire.eu/>
- [4] NetworkX — bibliothèque Python pour graphes.
<https://networkx.org/>
- [5] scikit-learn — apprentissage automatique en Python.
<https://scikit-learn.org/>
- [6] Folium — cartes interactives.
<https://python-visualization.github.io/folium/>

12 Annexes

12.1 Journal d'activité synthétique

Les notes prises au fil des séances de suivi (module *Graphes et Open Data*, encadré par Valentin Bouquet) ont guidé la structuration de ce rapport. Elles ne sont pas jointes en annexe : seul un **fil de progression** est retenu ci-dessous, pour situer l'évolution d'**OpenEURsearch-Graph** entre le cadrage initial (18 mars) et le dépôt du rapport (31 mai 2026), la soutenance orale ayant eu lieu le 22 mai, sans détailler chaque correction de code ou chaque run intermédiaire.

TABLE 11 – Repères chronologiques du projet (mars–mai 2026).

Date	Focus	Réalisations marquantes
18/03	Problématique	Cadrage CORDIS/OpenAlex ; articulation G_{ex} / G_{th} ; livrables (CSV, graphes, HTML).
27/03	Ingestion	Scripts fetch CORDIS, tests pandas/NetworkX, schéma des huit tables et règle <code>org_id</code> .
03/04	Réseaux	<code>clean_normalize.py</code> puis huit CSV, multiplexe GEXF, centralités sur le sous-graphe <code>org</code> .
10/04	Cartographie	Cartes Folium, filtre d'arêtes, structuration de <code>data/graphs/</code> .
17/04	Thématique	OpenAlex (financier CE), profils concepts, cosinus et seuil θ .
24/04	Écarts	Score π , export <code>gap_analysis_top.json</code> , métriques par établissement.
15/05	Pipeline	<code>run_pipeline.py</code> , <code>hub_interactive_suite.html</code> , provenance et agrégats temporels.
22/05	Soutenance	Démo orale (cartes, écarts, π), retours de l'encadrant.
31/05	Dépôt rapport	PDF XeLaTeX final, captures intégrées, remise MIAGE.

12.2 Flux technique simplifié

Chaîne reproductible CORDIS/OpenAlex → huit CSV `data/processed/` → GEXF multiplexe et G_{th} → JSON métriques, écarts, provenance → HTML Folium et `interactive_suite.html`. Paramètres de volumétrie et bornes navigateur nécessaires à des runs pragmatiques.

12.3 Annexe technique : commandes locales utiles

```

1 # Environnement
2 cd projet-graphe-recherche-eu && python3 -m venv env && source env/bin/
   activate
3 pip install -r requirements.txt
4
5 # Pipeline (bornes exemple)

```

```

6 python src/run_pipeline.py --max-rows 20000 --max-pages 5
7
8 # Rapport PDF (depuis rapport/premium/)
9 latexmk -xelatex -interaction=nonstopmode main.tex

```

12.4 Ouverture des vues interactives

Ouvrir `data/graphs/interactive_suite.html` après exécution, en conservant `data/graphs/` comme racine (URLs relatives des iframes). Onglets : `#carte-collaborations`, `#reseau-recherche`, `#demo-multi-projets`. Compléments directs : `map_concept_networkx_view.html`, `fiches org_profiles/<org>.html`.

12.5 Paramètres fréquemment ajustés

Option	Effet
<code>build_thematic_layer.py--threshold</code>	Seuil θ sur similarité cosinus (défaut 0,30).
<code>gap_analysis.py--min-score</code>	Filtre minimal $s_{\min}$ sur score thématique (défaut 0,40).
<code>visualize_folium.py--max-edges</code>	Borne d'arêtes affichées pour fluidité navigateur.

12.6 Index des figures et tables internes au rapport

Outre les captures interactives (figures 3 à 7), les schémas 1, 2 et le graphique 8 facilitent la compréhension de la chaîne ETL et des ordres de grandeur. Les tableaux 3, 4, 5, 1, 8, 9 et 7, ainsi que les équations 1–5, constituent la contrepartie analytique destinée aux relecteurs pressés.

12.7 Arborescence du dépôt

```

1 projet-graphe-recherche-eu/
2   data/raw/cordis/           # exports CORDIS
3   data/raw/openalex/        # JSON API
4   data/processed/           # 8 CSV
5   data/graphs/              # GEXF, JSON, HTML, org_profiles/
6   src/                      # scripts Python
7   rapport/premium/main.tex

```